Projets

Data Science sous R

3D & 3DG

2026–2027

1. Présentation générale

L'objectif de chaque projet est de simuler une situation réelle d'analyse marketing, dans laquelle les membres du groupe exploitent des données afin d'orienter la prise de décision. Chaque groupe traite un sujet, attribué par tirage au sort (section 5), à partir d'un jeu de données disponible dans un package R (`ISLR`, `datarium`, `bayesm`) ou fourni avec le cours. L'enjeu est de combiner la rigueur technique (préparation des données, modélisation, visualisation, évaluation) et l'interprétation stratégique adaptée à un contexte décisionnel en marketing.

2. Objectifs pédagogiques

À l'issue de ce projet, vous devriez être capables de :

1. Appliquer les techniques de science des données vues en cours comme les analyses descriptives, la régression, l'ANOVA, l'ACP, les arbres de décision et les forêts aléatoires, à des problèmes marketing.
2. Choisir une méthode adaptée à la question posée et justifier ce choix.
3. Évaluer la fiabilité de vos résultats : performances sur des données de test, stabilité, limites.
4. Mettre en œuvre un travail reproductible en R.
5. Interpréter et communiquer les résultats dans une perspective orientée « décision », et en tirer des recommandations marketing.

3. Modalités générales

— **Groupes :** 4 étudiants par groupe. La composition des groupes et le sujet de chacun figurent en section 5.

— **Livrables :**

i. Un résumé exécutif de 2 pages, destiné à un public non technique (direction marketing) : question, principaux résultats, recommandations, limites. Un modèle LaTeX est fourni (`modele-rapport/resume-executif.tex`).

ii. Un rapport technique complet en R Quarto : code, exploration des données, modélisation, évaluation et interprétation. Le rapport doit se régénérer entièrement à partir des données (bouton *Knit* ou *Render*). Un modèle de rapport Quarto est fourni (fichier `modele-rapport.zip`) : il charge les données de chaque sujet et indique le contenu attendu de chaque section.

iii. Une présentation orale de 10 à 12 minutes, suivie de questions, lors de la séance 6.

— **Évaluation :**

Critère	Poids
Rigueur analytique (méthodes adaptées, évaluation, reproductibilité)	40 %
Visualisation et communication	30 %
Pertinence stratégique et *storytelling*	30 %

— **Remarques :**

i. Veillez à la reproductibilité du code (projet RStudio, chemins relatifs, `set.seed()`), au respect de l'éthique des données et à la clarté des recommandations.

ii. Certains jeux de données servent d'exemples dans les notes de cours : votre analyse doit aller au-delà de ces exemples et répondre aux questions propres à votre sujet.

iii. L'objectif final est de produire une analyse marketing crédible et exploitable, comparable à une mission de conseil en science des données.

Démarche attendue

Quel que soit le sujet, suivez le cycle de vie d'un projet de science des données :

1. **Formuler** la question marketing et la décision qu'elle doit éclairer.
2. **Décrire les données** : origine, signification de chaque variable, qualité, limites.
3. **Explorer** : analyses univariées et bivariées, graphiques.
4. **Modéliser** : partir d'un modèle de référence simple, puis justifier les méthodes plus élaborées.

5. **Évaluer** : performances sur un jeu de test, stabilité des résultats (autre graine, autres choix de préparation ou de méthode).
6. **Communiquer** : message principal, recommandations chiffrées, limites et incertitudes.

4. Projets

1. Optimisation du mix marketing multicanal

Contexte : Une entreprise répartit son budget publicitaire entre YouTube, Facebook et la presse. La direction veut savoir quel canal rapporte le plus et comment répartir le budget.

Données : `marketing` du package `datarium` (`install.packages("datarium")`) : 200 observations (données simulées) ; budgets publicitaires `youtube`, `facebook`, `newspaper` (milliers de dollars) et ventes `sales` (milliers d'unités).

Questions : Quel est l'effet de chaque canal sur les ventes ? Les canaux se renforcent-ils mutuellement (synergies) ? Les rendements sont-ils décroissants ? Quel est le retour sur investissement de chaque canal ? À budget total constant, quelle répartition maximise les ventes prévues ?

Méthodes : Régression linéaire multiple, interactions, transformations (logarithme, racine carrée), comparaison de modèles (ANOVA, validation sur un jeu de test), forêt aléatoire en comparaison (chapitres 4 et 5).

Livrables : Modèle de mix marketing, ROI par canal, scénarios de répartition budgétaire et recommandations.

2. Les déterminants de la satisfaction client

Contexte : Un éditeur d'annuaires publicitaires (*Yellow Pages*) interroge ses clients annonceurs. Il veut savoir sur quels aspects de son offre agir en priorité pour améliorer leur satisfaction.

Données : `customerSat` du package `bayesm` : 1 811 répondants, 10 questions notées de 1 (« médiocre ») à 10 (« excellent ») : satisfaction globale (`q1`), prix (`q2` à `q4`), efficacité et audience de la publicité (`q5` à `q8`), distribution (`q9`, `q10`). Chargement : `install.packages("bayesm")` (une fois), puis `library(bayesm)` et `data(customerSat)`.

Questions : Quels aspects de l'offre sont les plus liés à la satisfaction globale ? Les neuf questions détaillées se résument-elles à quelques dimensions ? Existe-t-il des profils de clients distincts ? Certains répondants notent-ils systématiquement haut ou bas, et comment en tenir compte ?

Méthodes : Analyses descriptives et corrélations, ACP, régression, classification automatique (chapitres 3 à 6).

Livrables : Carte des leviers de satisfaction (importance et performance de chaque aspect), profils de clients et plan d'action priorisé.

3. Modélisation de la réponse à une offre commerciale

Contexte : Un assureur veut proposer une assurance pour caravane à ses clients par une campagne de marketing direct et ne contacter que les clients les plus susceptibles de souscrire.

Données : `Caravan` du package `ISLR` : 5 822 clients réels d'un assureur néerlandais ; 43 variables socio-démographiques (mesurées au niveau du code postal), 42 variables de détention de produits d'assurance et la souscription (`Purchase`), rare (environ 6 %).

Questions : Quel est le profil des souscripteurs ? Peut-on construire un score de propension fiable malgré le déséquilibre des classes ? Combien de clients faut-il contacter, compte tenu du coût d'un contact et de la marge d'un contrat ? Quels risques éthiques pose un ciblage fondé sur le quartier de résidence ?

Méthodes : Régression logistique, arbres et forêts aléatoires, courbe ROC, AUC, courbe de gain (*lift*), choix d'un seuil selon les coûts (chapitres 4 et 5).

Livrables : Modèle de réponse évalué sur un jeu de test, score client, analyse coût-bénéfice de la campagne et recommandations de ciblage.

4. Efficacité publicitaire selon le contexte local

Contexte : Un fabricant de sièges auto pour enfants vend dans 400 magasins et finance de la publicité locale. Il se demande si la publicité est aussi efficace partout et comment répartir son budget entre magasins.

Données : `Carseats` du package `ISLR` : 400 magasins (données simulées) ; ventes, prix pratiqué et prix du concurrent, budget publicitaire local, emplacement en rayon, caractéristiques de la zone (population, revenu, âge, zone urbaine, pays).

Questions : L'effet de la publicité dépend-il du type de magasin (zone urbaine ou non, États-Unis ou non, emplacement en rayon, revenu de la zone) ? Quelle est la sensibilité des ventes au prix, et dépend-elle du contexte ? Quels magasins sont prioritaires pour un euro de publicité supplémentaire ?

Méthodes : Régression multiple avec interactions, ANOVA, arbres et forêts aléatoires, segmentation des magasins (chapitres 4 à 6).

Livrables : Analyse de l'efficacité publicitaire par type de magasin, recommandations d'allocation du budget et de politique de prix.

5. Valeur client et fidélisation

Contexte : Une boutique en ligne veut identifier ses clients les plus précieux, comprendre ce qui fait leur valeur et réduire l'attrition.

Données : Boutique en ligne du cours (données simulées, voir le chapitre 3 des notes et la section « Les données du cours » du site des notes) : 2 000 clients, 9 508 commandes passées en 2025, catégories de produits avec leur taux de marge, résultats d'un test A/B d'emailing.

Questions : Comment mesurer la valeur d'un client (indicateurs RFM, marge générée) ? Quels facteurs (canal d'acquisition, newsletter, âge, catégories achetées, promotions) sont associés à une forte valeur ? Quels clients risquent de partir, et lesquels faut-il chercher à réactiver ? Quel enseignement tirer du test A/B ?

Méthodes : Manipulation de données avec `dplyr` (jointures, agrégations), régression, ANOVA, arbres et forêts aléatoires, test du χ^2 (chapitres 3 à 5).

Livrables : Indicateurs de valeur client, modèle explicatif de la valeur, liste de clients prioritaires et plan d'action de fidélisation.

6. Structure du marché et positionnement des marques

Contexte : Un distributeur de spiritueux veut comprendre comment ses clients consomment les différentes marques de whisky écossais : quelles marques sont en concurrence directe, lesquelles sont consommées ensemble ?

Données : `Scotch` du package `bayesm` (`data(Scotch)`) : 2 218 consommateurs réels de whisky (enquête Simmons) ; pour chacune des 21 marques, 1 si le consommateur l'a achetée au cours de l'année, 0 sinon.

Questions : Quelles sont les parts de pénétration des marques ? Quelles marques sont consommées ensemble ? Peut-on représenter les marques sur une carte qui rende compte de leur proximité ? Existe-t-il des groupes de consommateurs aux répertoires de marques distincts (fidèles à une marque, amateurs de marques haut de gamme…) ?

Méthodes : Analyses descriptives, corrélations entre marques, ACP sur les marques, classification automatique des marques et des consommateurs (chapitres 5 et 6).

Livrables : Carte du marché, segments de consommateurs et recommandations de positionnement et d'assortiment.

7. Prix, promotions et choix de marque

Contexte : Un fabricant de jus d'orange veut mesurer l'effet de ses prix, de ses remises et de ses mises en avant en magasin sur le choix des consommateurs face à son concurrent.

Données : `OJ` du package `ISLR` : 1 070 achats réels de jus d'orange de deux marques (Citrus Hill et Minute Maid) dans cinq magasins ; prix, remises, mises en avant, semaine d'achat et fidélité du client à la marque.

Questions : Quelle est la sensibilité du choix à l'écart de prix entre les marques ? Les remises et les mises en avant sont-elles efficaces, et dans quels magasins ? Quel rôle joue la fidélité ? Quel prix ou quelle promotion recommander pour gagner des parts de marché, selon le profil des clients ?

Méthodes : Régression logistique, rapports de cotes, arbres et forêts aléatoires, simulation de scénarios de prix (chapitres 4 et 5).

Livrables : Mesure de la sensibilité au prix et aux promotions, scénarios de prix, recommandations de politique promotionnelle.

5. Groupes

Groupe	Membres	Projet
1	Moé AL-ASBAHI Aymeric BONNANS Victor PREMAT Mélissa TRESO	6. Structure du marché et positionnement des marques
2	Lucas BRUNSCHWIG Jade IOUALALEN Joshua MAAREK Mia TEIXEIRA	2. Les déterminants de la satisfaction client
3	Chris BOUPASSIA Bertrand DE VERTEUIL Améziane HAOUANOH Léonie SCHMIT	5. Valeur client et fidélisation
4	Clara JULIEN Karl JUTTIN Harold MALHERBE Sana ZOUAOUI	1. Optimisation du mix marketing multicanal
5	Kenza LAAZIRI Jade MERLE-REMOND Emma NEDELEC Olivia PERET	4. Efficacité publicitaire selon le contexte local